

oi

Renato Moura Martins Medeiros

6 de Outubro de 2016



# Conteúdo

<b>1</b>	<b>Introdução</b>	<b>9</b>
<b>2</b>	<b>Preliminares</b>	<b>11</b>
2.1	Nomenclatura . . . . .	11
2.2	Trabalhos relacionados . . . . .	11
<b>3</b>	<b>Wavelets</b>	<b>13</b>
<b>4</b>	<b>Redes Neurais Artificiais</b>	<b>15</b>
4.1	Perceptron de Múltiplas Camadas . . . . .	15
4.2	O Algoritmo de Retropropagação . . . . .	16
4.2.1	Um exemplo numérico . . . . .	18
<b>5</b>	<b>Proposta de Trabalho</b>	<b>19</b>



# Lista de Figuras

4.1	Um Perceptron de Múltiplas Camadas com três camadas. Dois neurônios na primeira, três na segunda e apenas um na terceira. . . . .	15
4.2	Funcionamento interno de um neurônio, que recebe estímulo de dois neurônios da camada anterior. . . . .	16
4.3	Ilustração retirada de [12] onde o valor de cada pixel é enviado para um neurônio na camada de entrada . . . . .	17



# Lista de Tabelas





# **Capítulo 1**

## **Introdução**



# Capítulo 2

## Preliminares

Uma *Rede Neural Artificial* (RNA) é um modelo computacional capaz de abstrair uma determinada informação dado um conjunto de exemplos dela. Esquemáticamente, ela é representada na forma de um grafo [11] e é composta por unidades chamadas de *neurônios*, cujo objetivo principal é emular o funcionamento de um neurônio real, mesmo que de forma grosseira [7]. O *conhecimento* de uma rede neural artificial está no valor dos pesos que ligam seus neurônios, exceto em redes sem peso [1, 2], que não serão utilizadas nesse trabalho.

A larga utilização de redes neurais artificiais para a predição de valores em séries temporais [9, 8] se explica porque elas são ideais para esse propósito [5] e tem a capacidade de aproximar qualquer função, contínua ou não [3]. Para aumentar a acurácia na previsão da rede, recomenda-se pré-processar a série temporal com o objetivo de atenuar o seu ruído [4].

O uso de *onduletas*<sup>1</sup> é descrito por [15, 14] a fim de pré-processar séries temporais e, com isso, atenuar seu ruído. Onduletas são funções matemáticas que satisfazem certas condições e que são capazes de representar dados ou outras funções [6] tanto no eixo de frequências quanto no de tempo. Dentre as tantas onduletas existentes, a *Transformada de Haar* foi a escolhida para este trabalho porque, de acordo com [10], a transformada de Haar é matematicamente simples, converge rápido e possui alta precisão.

### 2.1 Nomenclatura

Seja  $y$  uma série temporal de  $Y$  elementos e  $y_i$  um elemento de  $y$  tal que  $0 < i < Y$ .

### 2.2 Trabalhos relacionados

---

<sup>1</sup>Embora a maioria dos autores prefira usar o termo em inglês *wavelet*, neste trabalho usamos o termo na língua portuguesa já que este foi o padrão escolhido nos demais termos usados no trabalho



## **Capítulo 3**

### **Wavelets**



# Capítulo 4

## Redes Neurais Artificiais

Redes neurais talvez sejam umas das ferramentas mais importantes na aprendizagem de máquina. Sua capacidade de aproximar qualquer função, mesmo as não-contínuas [3], tornam-nas importantes ferramentas para classificação e predição de séries.

Existem redes de aprendizado supervisionado, onde a rede precisa da resposta certa no seu treinamento, e de aprendizado não-supervisionado, onde esse valor não é necessário. O *treinamento* de uma rede perceptron de múltiplas camadas permite o ajuste dos pesos da rede de forma que ela responda a estímulos similares com um erro minimizado. Como o perceptron de múltiplas camadas se baseia em um aprendizado supervisionado, é necessário dispor do valor esperado como resposta da rede dada uma entrada.

### 4.1 Perceptron de Múltiplas Camadas

Em uma rede perceptron de múltiplas camadas, os neurônios estão contidos em conjuntos chamados *camadas*. Esquemáticamente, as camadas são perfiladas paralelamente de forma que a primeira recebe o nome de *camada de entrada* e a última de *camada de saída*. Toda e qualquer camada que esteja entre a camada de entrada e a camada de saída é chamada de *camada intermediária* ou, mais comumente, *camada oculta*. A Figura 4.1 apresenta um exemplo de uma rede perceptron de múltiplas camadas.

Cada neurônio pertence unicamente a uma camada e se conecta a todos os neurônios da camada seguinte. Essas conexões possuem um valor atribuído, chamado de *peso*. Na Figura 4.1 cada neurônio é representado por um círculo amarelo, enquanto cada peso é representado por  $P_{i,j}$ .

O interior de um neurônio possui duas funções, a *função de agrupamento* e a *função de ativação*, também chamada de *função de transição* ou *função de propagação*. Excetuando-se os neurônios na camada de entrada, os demais recebem vários estímulos, como o resultado dos neurônios da camada anterior, bem como os pesos de conexão. A função de agregação de um neurônio soma o produto da saída dos neurônios da camada anterior com seus respectivos pesos de conexão, conforme Equação 4.1.

$$f_{ag} = \sum_{n=0}^N P_n S_n \quad (4.1)$$

Na Equação 4.1,  $f_{ag}$  é a função de agregação de um neurônio qualquer,  $N$  é o número de neurônios na camada anterior,  $P_n$  é o peso de conexão entre o neurônio da camada anterior e o atual e  $S_n$  é o valor calculado pelo neurônio da camada anterior. Imaginar  $P$  como um vetor de pesos e  $S$  como um vetor de valores calculados pelos neurônios da camada anterior permite reescrever a Equação 4.1 conforme Equação 4.2, onde  $P^T$  é o vetor transposto de  $P$ .




Figura 4.1: Um Perceptron de Múltiplas Camadas com três camadas. Dois neurônios na primeira, três na segunda e apenas um na terceira.

$$f_{ag} = P^T \cdot S \quad (4.2)$$

Já a função de transição recebe o resultado da função de agregação e o usa para calcular a saída do neurônio. A Figura 4.2 esquematiza o funcionamento interno de um neurônio. O neurônio da Figura 4.2 recebe a resposta de dois neurônios da camada anterior, bem como o peso de conexão entre cada um desses neurônios e o atual.




Figura 4.2: Funcionamento interno de um neurônio, que recebe estímulo de dois neurônios da camada anterior.

Diferente do que acontece com a função de agregação, existem diversas funções de ativação que podem ser usadas em um perceptron de múltiplas camadas (**ENCONTRAR UM TRABALHO QUE FAÇA UM ESTUDO COMPARATIVO ENTRE ESSAS FUNÇÕES, OU QUE USE MAIS DE UMA FUNÇÃO PARA CITAR AQUI**). Inclusive, a última camada da rede pode ter uma função de transferência diferente das camadas anteriores, geralmente para normalizar a saída da rede [13].



## 4.2 O Algoritmo de Retropropagação

O algoritmo de retropropagação<sup>1</sup> foi proposto por **ENCONTRAR ARTIGO DE QUEM PROPÔS E COLOCAR AQUI** e tem por objetivo modificar os pesos da rede de forma que a diferença entre o valor de saída da rede e o valor real, também chamado de *erro de predição*, seja o menor possível. Ele se baseia no uso de métodos de otimização, como o método do gradiente.

O treinamento de uma rede perceptron de múltiplas camadas precisa de dois vetores de valores, um de entrada e outro de saída. O algoritmo possui duas grandes etapas; a alimentação da rede e a retropropagação do erro.

### Passo 1: Alimentação da rede

O vetor de entrada é o estímulo a ser passado para a rede; ele tem o mesmo tamanho da camada de entrada. Dessa forma, cada valor do vetor é passado diretamente para um neurônio, sem utilizar a função de agregação. A Figura 4.3 (retirada de [12]) ilustra como isso é feito nesse processo.

A saída de um neurônio é o valor da função de ativação nele presente. Se o neurônio estiver presente na camada de entrada ou em uma camada oculta, esse valor é passado a todos os neurônios da camada seguinte, cujas funções de agregação calculam o valor a ser passado para a sua função de ativação. Se o neurônio estiver presente na camada de saída, o valor calculado pelo neurônio será a resposta da rede naquele neurônio.

### Passo 2: Retropropagação do erro

Uma vez terminado o passo 1, a última camada da rede possui suas respostas para o estímulo passado. Tais respostas precisam ser comparadas com o vetor de saída, que possui as respostas esperadas pela rede. Dessa forma, o vetor de saída precisa ser do mesmo tamanho da camada de saída da rede.

A função de erro mais comum a ser utilizada para comparar a resposta da rede com o vetor de saída **ENCONTRAR ARTIGO QUE DIGA ISSO** é o erro quadrático (Equação 4.3, onde  $i$  é índice de um neurônio na camada de saída,  $y_i$  é o valor esperado para este neurônio e  $S_i$  é o valor que a rede respondeu).

$$E = \frac{1}{2} \sum_i (y_i - S_i)^2 \quad (4.3)$$

Deseja-se saber o quanto modificar o peso  $P_{i,j}$  na camada de saída modifica o erro  $E$  (Equação 4.3). Matematicamente, isso pode ser expressado pela Equação 4.4. A Equação 4.5 possui a expansão através da aplicação da regra da cadeia.

$$\frac{\partial E}{\partial P_{i,j}} \quad (4.4)$$

$$\frac{\partial E}{\partial P_{i,j}} = \frac{\partial E}{\partial S_{i,j}} * \frac{\partial S_{i,j}}{\partial E_{i,j}} * \frac{\partial E_{i,j}}{\partial P_{i,j}} \quad (4.5)$$

O primeiro termo da Equação 4.4

### 4.2.1 Um exemplo numérico

<sup>1</sup>Também chamado por alguns autores de *propagação de retorno do erro*




Figura 4.3: Ilustração retirada de [12] onde o valor de cada pixel é enviado para um neurônio na camada de entrada

## **Capítulo 5**

### **Proposta de Trabalho**



# Bibliografia

- [1] I. Aleksander, W. Thomas, and P. Bowden. Wisard-a radical step forward in image recognition. *Sensor Review*, 4(3):120–124, 1984.
- [2] W. W. Bledsoe and I. Browning. Pattern recognition and reading by machine. In *Papers Presented at the December 1-3, 1959, Eastern Joint IRE-AIEE-ACM Computer Conference*, IRE-AIEE-ACM '59 (Eastern), pages 225–232, New York, NY, USA, 1959. ACM.
- [3] B. de Assis Pio. *Uma Introdução às Redes Neurais Artificiais para Estudos em Ecologia*. Bruno Luiz de Assis Pio, 2009.
- [4] J. Gao, H. Sultan, J. Hu, and W. W. Tung. Denoising nonlinear time series by adaptive filtering and wavelet shrinkage: A comparison. *IEEE Signal Processing Letters*, 17(3):237–240, March 2010.
- [5] C. R. Gent and C. P. Sheppard. Predicting time series by a fully connected neural network trained by back propagation. *Computing Control Engineering Journal*, 3(3):109–112, May 1992.
- [6] A. Graps. An introduction to wavelets. *IEEE Computational Science and Engineering*, 2(2):50–61, Summer 1995.
- [7] K. Gurney. *An Introduction to Neural Networks*. Taylor & Francis, 2003.
- [8] J. M. Kuo, J. C. Principe, and B. de Vries. Prediction of chaotic time series using recurrent neural networks. In *Neural Networks for Signal Processing [1992] II., Proceedings of the 1992 IEEE-SP Workshop*, pages 436–443, Aug 1992.
- [9] S. S. Rao, S. Sethuraman, and V. Ramamurti. A recurrent neural network for nonlinear time series prediction-a comparative study. In *Neural Networks for Signal Processing [1992] II., Proceedings of the 1992 IEEE-SP Workshop*, pages 531–539, Aug 1992.
- [10] A. Reddy, S. Manjula, C. Sateesha, and N. Bujurke. Haar wavelet approach for the solution of seventh order ordinary differential equations. *MMEP*, 3(2):108–114, jun 2016.
- [11] D. Skapura. *Building Neural Networks*. ACM Press Series. ACM Press, 1996.
- [12] D. Skapura. *Building Neural Networks*. ACM Press Series. ACM Press, 1996.
- [13] P. Swietojanski and S. Renals. Learning hidden unit contributions for unsupervised speaker adaptation of neural network acoustic models. In *Spoken Language Technology Workshop (SLT), 2014 IEEE*, pages 171–176, Dec 2014.
- [14] L. Wang, K. K. Teo, and Z. Lin. Predicting time series with wavelet packet neural networks. In *Neural Networks, 2001. Proceedings. IJCNN '01. International Joint Conference on*, volume 3, pages 1593–1597 vol.3, 2001.

- [15] Q. Zhang and A. Benveniste. Wavelet networks. *IEEE Transactions on Neural Networks*, 3(6):889–898, Nov 1992.